

ESPRIT

École Supérieure Privée d'Ingénierie et de Technologies

Année universitaire 2026–2027

RAPPORT DE STAGE

Conception et développement d'une plateforme intelligente de traitement documentaire basée sur l'OCR et l'analyse automatisée des cahiers des charges

De l'extraction de texte aux preuves exploitables pour l'analyse des appels d'offres

Réalisé par

Aymen Dhieb

Classe

5DS3

Spécialité

Data Science / Intelligence Artificielle

Entreprise

UDGroup – Universal Digital Group

Période

du 01/07/2026 au 31/08/2026

Deux mois de stage d'ingénierie

Remerciements

Je remercie UDGroup – Universal Digital Group pour l'accueil dans le cadre de ce stage et pour l'occasion d'aborder un problème concret de traitement documentaire. Cette mission m'a conduit à articuler extraction de texte, modélisation de la preuve, analyse métier et validation logicielle. Je remercie également les personnes ayant contribué aux échanges techniques et à la relecture des besoins. Le présent rapport restitue les réalisations vérifiables dans le dépôt du projet, ainsi que leurs limites.

Résumé

Les cahiers des charges mêlent texte narratif, articles, annexes et bordereaux. Leur exploitation ne se réduit pas à reconnaître les caractères d'un PDF : une information utile doit être replacée dans sa structure et reliée à la page qui la justifie. Ce stage chez UDGroup a porté sur une progression en deux étapes. La première établit un producteur générique de *Document Intelligence* pour PDF et images. Il sélectionne par page l'extraction native ou l'OCR, harmonise les coordonnées et publie un contrat de preuve composé de pages, d'éléments textuels, de géométrie et de diagnostics. La seconde applique cette base aux cahiers des charges : hiérarchie, exigences candidates, échéances, annexes, détection et lecture de bordereaux, interrogation documentaire, stockage local et espace de chiffrage avec revue humaine.

L'évaluation distingue rigoureusement les documents réels, les exemples synthétiques et les observations de développement. Le document réel de référence est un bordereau vide : cinq lignes structurelles sont détectées, mais la précision d'extraction des prix sur des offres remplies n'est pas mesurable. Le corpus CDC annoté constitue un ensemble de développement, et la récupération Ask Tender est évaluée seulement sur de petites questions synthétiques. Cette transparence conduit à un résultat exploitable pour une démonstration locale supervisée, avec un programme clair de validation supplémentaire avant tout usage de production.

Mots-clés : OCR ; Document Intelligence ; cahier des charges ; provenance ; bordereau ; extraction d'information ; évaluation.

Abstract

Tender specifications mix prose, clauses, annexes, and bills of quantities. Character recognition alone is insufficient: useful information needs a structural context and a traceable source page. This internship at UDGroup followed two engineering stages. First, a generic Document Intelligence producer handles PDFs and images, selects native text or OCR on each page, normalizes coordinates, and publishes evidence with text elements, geometry, and diagnostics. Second, tender-specific modules derive hierarchy, candidate requirements, deadlines, annexes, BOQ structures, evidence-grounded retrieval, local persistence, and a separate pricing draft with human review.

The evaluation keeps real documents, synthetic fixtures, and development observations apart. The real BOQ reference is an empty template: five structural row slots are recovered, while numeric accuracy on completed tenders cannot be measured. The annotated CDC corpus is a development set; Ask Tender retrieval has only small synthetic question sets. The current result supports a supervised local demonstration and defines concrete validation work before production use.

Keywords: OCR; Document Intelligence; tender specification; provenance; bill of quantities; information extraction; evaluation.

Table des matières

Remerciements	i
Résumé	ii
Abstract	iii
Liste des abréviations	viii
Introduction générale	1
1 UGroup, mission et organisation du travail	2
1.1 Présentation de l'entreprise	2
1.2 Contexte, objectifs et périmètre	2
1.3 Méthodologie de travail	2
1.4 Organisation, suivi et reconstruction des phases	3
1.5 Contributions personnelles et limites d'attribution	4
2 Problématique et analyse des besoins	5
2.1 Du fichier à l'information vérifiable	5
2.2 Besoins fonctionnels	5
2.3 Besoins non fonctionnels et critères d'acceptation	5
2.4 Acteurs, scénarios et frontière de confiance	7
3 État de l'art ciblé et choix techniques	8
3.1 OCR et extraction native : deux sources différentes	8
3.2 Trois architectures possibles pour comprendre un dossier	9
3.3 De l'extraction à l'interprétation documentaire	9
3.4 Récupération, génération et preuve	10
3.5 Approche de validation	10
4 Tâche 1 : fondation OCR et Document Intelligence	11

4.1	Objectif et contrat de sortie	11
4.2	Décision native ou OCR par page	11
4.3	Reconnaissance et prétraitement	12
4.4	Modèle de preuve et géométrie	13
4.5	Difficultés, vérification et limites	13
5	Tâche 2 : intelligence des cahiers des charges	15
5.1	Passage de la preuve au domaine métier	15
5.2	Structure : titres, parties, articles et annexes	15
5.3	Exigences, délais et données financières	16
5.4	Détection et extraction des bordereaux	16
5.5	Le cas décisif du formulaire vide	17
5.6	Ask Tender : retrouver avant de formuler	18
5.7	Persistance, interface et chiffrage	20
6	Validation, résultats et analyse des erreurs	22
6.1	Protocole : trois niveaux de preuve	22
6.2	Tests du logiciel et contrat documentaire	22
6.3	Mesures CDC et interprétation	23
6.4	Bordereau et contrôle de l'absence	23
6.5	Ask Tender et parcours utilisateur	24
6.6	Temps observés et erreurs résiduelles	24
7	Exécution locale, limites et perspectives	26
7.1	Architecture exécutable	26
7.2	Limites opérationnelles et scientifiques	26
7.3	Feuille de route fondée sur les erreurs	27
	Conclusion générale	28
	Références	29
A	Traçabilité de l'évaluation	30
A.1	Commandes et artefacts	30
A.2	Exemples de routes de consultation	30
A.3	Lecture prudente des nombres	30

Table des figures

1	Progression conceptuelle du projet. L'ordre pédagogique ne date pas les étapes dans les deux mois administratifs du stage.	1
1.1	Boucle de travail reconstituée à partir des contrats, régressions et corrections versionnées ; elle ne représente pas des cérémonies de projet.	3
1.2	Reconstruction fonctionnelle des phases du travail. Les jalons Git datent de septembre–octobre 2026 et ne datent pas les activités de juillet–août.	4
2.1	Architecture globale : la preuve reste un contrat explicite entre reconnaissance documentaire, interprétation métier et actions de l'analyste.	6
2.2	Parcours métier de l'analyste d'appel d'offres dans le prototype local ; les valeurs restent à vérifier dans le document source.	7
4.1	Pipeline de <code>DocumentProcessor</code> d'après le code et le contrat V1.	12
4.2	Normalisation des boîtes natives et OCR vers le même espace d'affichage.	13
5.1	Hierarchie simplifiée du modèle CDC ; les lots restent distincts des sections.	16
5.2	Extraction BOQ spécialisée ou générique, suivie de contrôles explicites.	17
5.3	Extrait authentique de l'Annexe 05 du PDF de référence, page 25 : emplacements de bordereau non remplis.	18
5.4	Vue réelle d'Ask Tender sur une fixture BOQ synthétique : passages cités et indisponibilité explicite de la génération locale.	19
5.5	Workspace exécuté localement avec la fixture BOQ synthétique : structure à gauche, document source au centre et analyse à droite.	20
5.6	Brouillon de chiffrage sur la même fixture synthétique : origine des valeurs et état « à vérifier » après une saisie divergente.	21
6.1	Maturité des preuves d'évaluation : la largeur décroissante signale le travail restant, sans convertir les niveaux en score de précision.	22

Liste des tableaux

1.1	Correspondance analytique avec des principes de CRISP-DM, sans conformité méthodologique revendiquée.	3
1.2	Synthèse des travaux visibles sous l'identité Git de l'étudiant ; la datation intra-stage n'est pas établie.	4
2.1	Besoins fonctionnels couverts par le système local.	6
2.2	Critères de qualité et niveau de vérification observé.	7
3.1	Technologies effectivement mobilisées ; les performances ne sont pas comparées entre produits.	8
3.2	Comparaison raisonnée d'architectures documentaires ; aucune supériorité chiffrée n'est revendiquée.	9
4.1	Responsabilités et limites du contrat de preuve.	13
4.2	Réponses d'ingénierie et limites de la fondation documentaire.	14
5.1	Portée effective des deux extracteurs BOQ.	17
6.1	Séparation des cohortes et limites de mesure.	23
6.2	Résultats du benchmark CDC V2 sur annotations de développement ; aucune métrique globale n'est déduite.	24
6.3	Observations d'une seule exécution locale, sans garantie de latence.	25
6.4	Erreurs conservées dans l'analyse plutôt que masquées par un score global. . . .	25
7.1	Limites à lever avant une exploitation au-delà d'une démonstration supervisée. .	27
A.1	Sélection de routes V2 du parcours CDC ; les points de suspension abrègent le préfixe <code>/api/v2/cdc/{id}</code>	30

Liste des abréviations

API	Interface de programmation d'application
BOQ	<i>Bill of Quantities</i> , bordereau de quantités et de prix
CDC	Cahier des charges
CSV	<i>Comma-Separated Values</i> , format tabulaire texte
DI	<i>Document Intelligence</i> , structuration d'informations documentaires
HT / TTC	Hors taxes / toutes taxes comprises
OCR	<i>Optical Character Recognition</i> , reconnaissance optique de caractères
PDF	<i>Portable Document Format</i>
RAG	<i>Retrieval-Augmented Generation</i> , génération assistée par récupération
TVA	Taxe sur la valeur ajoutée

Introduction générale

Une organisation qui prépare une réponse à un appel d'offres doit retrouver des obligations, des dates, des pièces à fournir et parfois des tableaux de prix dispersés sur de nombreuses pages. Les PDF reçus ne présentent pas tous la même structure : certains contiennent une couche de texte exploitable, d'autres sont des scans, et un dossier peut combiner les deux. Une lecture manuelle reste indispensable pour les décisions engageantes, mais elle peut être aidée par une extraction qui ramène chaque information à sa page et à sa zone d'origine.

La reconnaissance optique de caractères (OCR) transforme une image de texte en éléments textuels. Elle ne dit pas, à elle seule, si une phrase énonce un délai, une obligation ou un prix. La *Document Intelligence* étudiée ici ajoute un contrat commun de preuve, puis une interprétation propre au domaine des cahiers des charges (CDC). Le projet ne cherche donc pas à remplacer le jugement de l'analyste ; il organise des candidats vérifiables et les rend consultables dans un espace de travail.

L'objectif du stage, réalisé chez UDGroup du 1^{er} juillet au 31 août 2026, est présenté en deux tâches complémentaires. La première construit une fondation générique pour documents PDF et images : chargement, extraction native ou OCR, coordonnées, ordre de lecture, géométrie et diagnostics. La seconde transforme ces preuves en information de marché : sections, articles, exigences, informations temporelles et financières, annexes, bordereaux et réponses accompagnées de citations. La figure 1 résume cette progression.




FIGURE 1 – Progression conceptuelle du projet. L'ordre pédagogique ne date pas les étapes dans les deux mois administratifs du stage.

Ce rapport repose sur le code, les tests, les artefacts d'évaluation et l'historique Git accessibles à sa rédaction. Les premiers commits visibles datent du 28 septembre 2026, après la période administrative du stage. Leur ordre éclaire l'évolution technique sans dater précisément chaque fonction pendant juillet–août. Les résultats synthétiques sont désignés comme tels et le BOQ réel vide n'est jamais utilisé comme preuve de précision numérique. Les chapitres suivent les deux tâches, puis examinent leur évaluation et leurs limites.

Chapitre 1

UDGroup, mission et organisation du travail

1.1 Présentation de l'entreprise

UDGroup, pour Universal Digital Group, se présente sur son site officiel comme une entreprise de solutions numériques. Les offres visibles comprennent notamment le commerce électronique, la conception et le développement web, les applications ainsi que des services de marketing numérique [1]. Cette présentation publique situe le stage dans un environnement de réalisation logicielle ; elle ne prouve ni commercialisation de la plateforme étudiée ni déploiement chez un client.

1.2 Contexte, objectifs et périmètre

Un cahier des charges (CDC) réunit des conditions administratives, des contraintes techniques, des annexes et parfois un bordereau des prix (BOQ). Pour préparer une réponse, l'analyste doit retrouver ces informations, puis vérifier leur formulation dans le document. Le problème du stage est de transformer des PDF et images hétérogènes en candidats structurés *rattachés à leur preuve*, sans automatiser la décision contractuelle. Deux objectifs techniques en découlent : construire une fondation de *Document Intelligence* réutilisable et l'exploiter dans une analyse spécialisée des appels d'offres.

La période administrative va du 1^{er} juillet au 31 août 2026. Le dépôt accessible au moment de cette revue ne fournit pas de journal daté de ces deux mois ; ses commits visibles commencent le 28 septembre. On peut donc reconstruire l'ordre des changements versionnés et leurs dépendances, mais pas attribuer chaque implémentation à une semaine du stage. Le moteur OCR préexistant, issu d'un flux de factures, est considéré comme une infrastructure réutilisée ; les règles de facture ne sont pas assimilées aux règles CDC.

1.3 Méthodologie de travail

Les traces techniques soutiennent une démarche *itérative, incrémentale et orientée expérimentation*. Le contrat `DocumentResult`, les fixtures, les tests et les rapports d'erreur montrent une boucle récurrente : formuler une hypothèse sur le document, implémenter une règle ou un adaptateur, vérifier sur un cas contrôlé, analyser les erreurs, puis intégrer la correction.

Les commits `1a62803` (titres arabes et lots), `8aa82ab` (preuves BOQ) et `f292de8` (en-têtes et désignations repliées) illustrent cette logique. Ils ne documentent pas des réunions, rôles ou cérémonies Scrum ; aucune adoption formelle de Scrum n’est revendiquée.




FIGURE 1.1 – Boucle de travail reconstituée à partir des contrats, régressions et corrections versionnées ; elle ne représente pas des cérémonies de projet.

Cette démarche partage des principes avec les phases de CRISP-DM, sans que le dépôt atteste l’application formelle de cette méthode [2]. Le parallèle est utile pour montrer qu’une réalisation en Data Science/IA comprend aussi la compréhension des données, leur préparation et l’évaluation, et pas seulement l’entraînement d’un modèle. Le tableau 1.1 rattache chaque rapprochement à une trace concrète. « Déploiement » signifie ici intégration locale du prototype, non mise en production.

Principe rapproché	Application dans ce travail	Trace contrôlable
Compréhension métier	Repérer obligations, délais et prix à vérifier	Contrat CDC, routes et vues métier
Compréhension des données	Distinguer PDF natifs, scans, annexes et tableaux	Corpus de développement et référence BOQ
Préparation	Texte natif/OCR, pages, boîtes et provenance	<code>DocumentProcessor</code> , schémas V1
Traitement	Analyse CDC, extracteurs BOQ, récupération Ask Tender	Modules <code>app/cdc_analysis</code> , <code>app/boq</code> , <code>app/ask_tender</code>
Évaluation	Fixtures, annotations de développement, analyse d’erreurs	<code>tests/</code> , <code>benchmarks/</code> , rapports d’évaluation
Intégration locale	API, espace de travail et persistance	Routes V2, <code>LocalDocumentStore</code>

TABLE 1.1 – Correspondance analytique avec des principes de CRISP-DM, sans conformité méthodologique revendiquée.

1.4 Organisation, suivi et reconstruction des phases

Git et GitHub fournissent l’historique technique des changements ; les tests automatisés et les rapports d’évaluation en vérifient le comportement. Les vues de l’application et les parcours navigateur documentent le contrôle fonctionnel. Le brief étudiant mentionne Notion comme outil souhaité d’organisation, mais aucun export, tableau ou capture de cet espace n’a été retrouvé. Son usage concret, ses colonnes et sa fréquence de mise à jour ne sont donc pas décrits ici. Une capture authentique permettrait de compléter ce point sans confondre support de suivi et méthode de développement.

La figure 1.2 sépare la période administrative du stage et la succession *fonctionnelle* que les fichiers permettent d’établir. Les phases ne sont affectées ni à juillet ni à août : les dates de

commit postérieures ne constituent pas une preuve de dates de réalisation pendant le stage.

Période administrative attestée



Ordre fonctionnel reconstitué, sans semaine attribuée



FIGURE 1.2 – Reconstruction fonctionnelle des phases du travail. Les jalons Git datent de septembre–octobre 2026 et ne datent pas les activités de juillet–août.

1.5 Contributions personnelles et limites d’attribution

Git ne montre qu’une identité d’auteur : `aymendhieb02`. Le code, les tests et les documents corroborent la réalisation technique des changements ci-dessous ; ils ne suffisent pas à prouver seuls le temps exact, le degré d’aide externe ou l’intégralité du travail effectué pendant les deux mois administratifs. La formulation « contribution » décrit donc le travail attribuable dans le dépôt et demeure à confirmer dans le récit final par l’étudiant et l’entreprise.

Axe	Contribution technique attribuable	Apport observable
Fondation documentaire	Contrat <code>DocumentResult</code> , traitement multipage, voie native/OCR, coordonnées	Preuves réutilisables par plusieurs consommateurs
Analyse CDC	Hiérarchie, exigences candidates, faits et annexes, titres multilingues	Informations structurées avec références de page
Bordereaux	Extracteur spécialisé et candidat générique, validation et absences explicites	Lignes et contrôles sans prix inventés
Recherche	Ask Tender lexical, citations et génération locale optionnelle	Accès rapide à des passages vérifiables
Produit local	API V2, workspace, stockage, revue et brouillon de chiffrage	Réouverture, consultation et action humaine distincte de la source
Validation	Fixtures, régressions, corpus de développement et rapports de limites	Erreurs mesurables, sans score global abusif

TABLE 1.2 – Synthèse des travaux visibles sous l’identité Git de l’étudiant ; la datation intra-stage n’est pas établie.

L’apport propre à une spécialisation Data Science/IA est ici la chaîne complète : données non structurées, reconnaissance, normalisation, extraction, récupération, vérité terrain partielle, analyse d’erreurs et validation humaine. Le rapport ne prétend pas qu’un nouveau réseau neuronal a été entraîné. Sa contribution intellectuelle centrale est la continuité de la provenance, du document jusqu’à la décision assistée.

Chapitre 2

Problématique et analyse des besoins

2.1 Du fichier à l'information vérifiable

Un même dossier d'appel d'offres peut mélanger pages narratives, formulaires, annexes et tableaux. Les mots reconnus ne suffisent pas : il faut distinguer une date limite d'une date de publication, une garantie provisoire d'une garantie définitive et un montant du document d'un montant calculé par l'utilisateur. L'enjeu est double. D'une part, automatiser les opérations répétitives de localisation et de structuration. D'autre part, réduire le risque d'interprétation silencieuse en conservant la page, la zone et le texte à l'origine de chaque candidat.

La question d'ingénierie est donc : *comment produire, à partir de PDF et d'images hétérogènes, un espace d'analyse des CDC qui aide à repérer les informations utiles sans masquer l'incertitude de l'extraction ?* Elle se décompose en acquisition, normalisation de preuves, interprétation métier, restitution et validation. La figure 2.1 expose les contrats entre ces responsabilités et les outils de décision.

2.2 Besoins fonctionnels

Les exigences du tableau 2.1 sont déduites des routes, des classes et des vues effectivement présentes. Le terme « candidat » est conservé pour les informations qui réclament une validation humaine.

2.3 Besoins non fonctionnels et critères d'acceptation

La *traçabilité* exige que l'information extraite puisse être ramenée au document, à la page et aux éléments textuels. La *robustesse* suppose d'explicitier les cases absentes plutôt que de les convertir en zéro. La *reproductibilité* nécessite des fixtures versionnées et une suite de tests. La *confidentialité* motive l'exécution locale des traitements et une génération Ollama seulement optionnelle ; elle ne remplace toutefois ni authentification ni politique de conservation. Enfin, la *maintenabilité* réclame des contrats stables entre le producteur générique et ses consommateurs.




FIGURE 2.1 – Architecture globale : la preuve reste un contrat explicite entre reconnaissance documentaire, interprétation métier et actions de l’analyste.

Code	Besoin	Preuve d’implémentation
F1	Charger un PDF ou une image et conserver les pages physiques	DocumentProcessor, API d’analyse
F2	Extraire le texte natif ou OCR et ses coordonnées	processor.py, schemas.py
F3	Repérer sections, articles, lots, annexes et exigences candidates	CDCAnalyzer, schéma TenderDocument
F4	Détecter et reconstruire des lignes BOQ lorsque le format est couvert	Modules boq/detect, extractor, generic
F5	Ouvrir le passage source d’une information ou d’une réponse	Références de preuve, visualiseur de page
F6	Interroger le document par récupération de passages	ask_tender/service.py
F7	Sauvegarder, rechercher et rouvrir l’analyse	LocalDocumentStore, bibliothèque
F8	Saisir des prix sans écraser les valeurs sources	boq/pricing.py, espace de chiffrage

TABLE 2.1 – Besoins fonctionnels couverts par le système local.

Qualité	Critère concret	Vérification disponible
Provenance	Page physique, élément source et coordonnées conservés	Schémas, tests de géométrie et de contrat
Absence explicite	Champ non renseigné = valeur nulle, calcul non vérifiable	Référence BOQ vide et tests de validation
Reproductibilité	Entrée et attendu versionnés	Fixtures synthétiques, vérité terrain et pytest
Réutilisation	OCR séparé des règles CDC/BOQ	Contrats <code>DocumentResult</code> et adaptateurs
Usage local	Réouverture de l'analyse sans réexécuter le PDF	Stockage et tests API de rechargement
Sécurité	Accès réservé à l'environnement local supervisé	Limite explicitée : authentification absente

TABLE 2.2 – Critères de qualité et niveau de vérification observé.

2.4 Acteurs, scénarios et frontière de confiance

L'utilisateur charge un CDC ; le serveur enregistre un identifiant opaque et l'interface affiche sections, faits, annexes et bordereaux. L'analyste peut ouvrir une preuve, interroger le document et saisir un prix dans un brouillon distinct. La revue peut approuver ou corriger certains faits financiers. L'analyste reste responsable de confronter les propositions à la source : aucune réponse générée n'est juridiquement validée. Un PDF chargé est une donnée non fiable, et l'application locale n'a pas de contrôle d'accès multi-utilisateur. Le critère d'acceptation est une démonstration supervisée, sans décision contractuelle automatique.

La figure 2.2 reformule le système du point de vue de l'employé. Chaque résultat important mène à la page source ; la correction et le prix saisi sont des actions humaines, séparées de la valeur extraite. L'enregistrement local permet de reprendre une analyse, sans présumer d'un circuit officiel de soumission.




FIGURE 2.2 – Parcours métier de l'analyste d'appel d'offres dans le prototype local ; les valeurs restent à vérifier dans le document source.

Chapitre 3

État de l’art ciblé et choix techniques

3.1 OCR et extraction native : deux sources différentes

Un PDF numérique peut contenir des glyphes et des positions extractibles directement. PyMuPDF expose notamment l’extraction de mots et prévient que l’ordre textuel du PDF ne correspond pas nécessairement à l’ordre de lecture visuel [3]. Un scan, au contraire, exige une reconnaissance sur pixels. PaddleOCR est le moteur de reconnaissance principal prévu par le dépôt ; son installation et ses modèles constituent une dépendance d’exécution distincte [4]. Tesseract peut jouer un rôle de repli si son exécutable et ses données de langue sont installés [5]. La solution ne suppose pas qu’un des deux chemins soit universellement meilleur : elle choisit au niveau de la page et consigne la décision.

L’OCR produit généralement des lignes accompagnées d’une confiance du reconnaisseur, alors que l’extraction native fournit des mots sans confiance OCR. Mélanger ces valeurs dans un score unique serait trompeur. Le contrat conserve donc la source (**native_pdf**, **paddleocr**, **tesseract**), les boîtes d’origine et la transformation vers un repère commun. La tableau 3.1 synthétise les composants réellement présents.

Technologie	Fonction dans le dépôt	Motif vérifiable du choix
Python / Pydantic	Modèles de sortie et traitement	Contrats sérialisables et validation de types
PyMuPDF	Lecture PDF native et rendu des pages	Mots avec positions et rendu pour OCR
PaddleOCR	Reconnaissance sur images	Adapteurs et profils OCR réutilisés
Tesseract	Repli local optionnel	Garde une voie de secours, sous condition d’installation
FastAPI	Routes d’analyse et de restitution	Contrats HTTP et validation d’entrées
HTML / CSS / JS	Workspace de consultation	Navigation vers les preuves et saisie de brouillon
Ollama	Génération locale optionnelle	Réponse textuelle depuis passages, repli sans modèle
pytest	Régressions et tests API	Vérification déterministe reproductible

TABLE 3.1 – Technologies effectivement mobilisées ; les performances ne sont pas comparées entre produits.

3.2 Trois architectures possibles pour comprendre un dossier

Une première famille associe OCR, expressions régulières et règles de structure. Elle permet de contrôler localement chaque transformation et de conserver une page de provenance, mais la couverture des formulations inédites dépend du travail explicite de normalisation. Une deuxième famille apprend conjointement texte, géométrie et image : LayoutLM a montré l'intérêt du placement des mots pour l'extraction documentaire [6], et LayoutLMv2 ajoute des interactions visuelles plus riches [7]. LayoutXLM étend ce principe au multilingue, mais son benchmark XFUND publié ne contient pas l'arabe ; son résultat ne peut donc pas être transposé directement au scan arabe du présent projet [8]. Donut étudie même une voie sans OCR séparé, susceptible d'éviter la propagation de certaines erreurs de reconnaissance, au prix d'une autre chaîne de modèles et de données [9].

Ces travaux constituent des alternatives scientifiques, pas des composants installés dans le dépôt. Une analyse de bout en bout par modèle de vision-langage pourrait mieux couvrir des mises en page nouvelles et des questions ouvertes ; elle demanderait toutefois un protocole de validation des valeurs, de leur localisation et des ressources d'inférence adapté aux dossiers confidentiels. La voie choisie ici est hybride au sens *architecture de preuve + interprétation spécialisée + génération optionnelle*, et non au sens d'un modèle multimodal entraîné. La tableau 3.2 explicite ce compromis sans supposer qu'une méthode domine universellement.

Approche	Force	Limite à mesurer	Adéquation au prototype
OCR et règles seules	Locales, déterministes, auditables	Variations de langue et de structure peu couvertes	Base utile, insuffisante pour tous les CDC
Analyse neuronale de page ou de bout en bout	Interactions texte-image-layout, souplesse potentielle	Données annotées, calcul et attribution précise à contrôler	Piste de comparaison future, non évaluée ici
Preuve structurée puis modules métier	Source explicite, contrats réutilisables, revue humaine	Ingénierie des schémas et heuristiques, généralisation à tester	Choix implémenté pour un prototype vérifiable

TABLE 3.2 – Comparaison raisonnée d'architectures documentaires ; aucune supériorité chiffrée n'est revendiquée.

3.3 De l'extraction à l'interprétation documentaire

La *Document Intelligence* désigne ici la transformation d'un fichier en éléments textuels localisés et structurés, puis leur exploitation par un analyseur métier. La géométrie aide à regrouper les fragments d'une même ligne et à repérer des colonnes potentielles, mais elle ne constitue pas une compréhension automatique du tableau. Le producteur générique ne crée pas de « prix » : ce sens est ajouté par le consommateur BOQ après détection d'un en-tête et association de cellules. La même séparation s'applique aux obligations : un titre d'article ne devient pas une exigence seulement parce qu'il est en gras ou numéroté.

Les règles déterministes ont des avantages dans ce contexte : elles sont inspectables, simples à versionner et peuvent retourner une absence explicite. Elles ont aussi des limites de couverture face aux paraphrases, aux langues et aux mises en page inédites. Le choix architectural observé combine des règles structurales pour les champs critiques avec un mécanisme de recherche de passages pour les questions ouvertes. Il n'y a pas dans le dépôt de base vectorielle ni d'embeddings servant à Ask Tender ; la récupération reste lexicale et enrichie par une petite carte de concepts.

3.4 Récupération, génération et preuve

La littérature RAG distingue l'accès à des passages et la génération conditionnée par ces passages [10]. Dans l'application, l'interrogation se décompose en normalisation de la question, recherche parmi des preuves structurées ou textuelles, classement, puis production d'une réponse courte. Une génération via Ollama peut être tentée localement, mais son indisponibilité laisse une réponse fondée sur les passages récupérés. Il serait excessif de décrire le mécanisme comme une recherche sémantique vectorielle ou de déduire la fidélité d'une réponse de la seule présence de citations.

La séparation entre reconnaissance, modèle de preuve et analyse métier est maintenant représentée dans la figure d'architecture globale (figure 2.1) plutôt que répétée sous une forme plus petite.

3.5 Approche de validation

Une suite logicielle peut vérifier les transformations, les calculs et les routes sans mesurer la qualité sur des documents inconnus. La présente étude sépare donc trois plans : conformité du code à ses contrats, comparaison avec des annotations de développement, et démonstration d'un parcours local. En recherche d'information, le rang d'un passage pertinent et la justesse de la réponse finale sont également des objets différents [11]. Cette séparation protège des conclusions abusives. Une précision de 100 % sur quelques listes d'annexes entièrement annotées ne vaut pas précision de toutes les informations d'un appel d'offres ; un top 1 sur des questions synthétiques ne vaut pas exactitude générale des réponses.

Chapitre 4

Tâche 1 : fondation OCR et Document Intelligence


4.1 Objectif et contrat de sortie

Le besoin initial est de rendre exploitables des PDF et images de nature différente sans enfermer l'extraction dans un formulaire métier. Le producteur `DocumentProcessor` accepte des PDF multipages et des images, y compris certaines images multiframe. Son résultat `DocumentResult` contient un identifiant dérivé du contenu, le mode demandé, des `PageResult` et des diagnostics. Chaque page conserve son numéro physique, ses dimensions, des `EvidenceElement` et des regroupements géométriques prudents. Le contrat public est versionné 1.0 hors de la forme JSON ; des fixtures de schéma le verrouillent.

Cette conception établit une frontière utile. Un élément peut contenir « délai de livraison » sans que le producteur n'en déduise une durée. La valeur métier naît plus loin, dans le CDC Analyzer. Inversement, un consommateur peut citer l'identifiant de l'élément original au lieu de recopier un texte qui aurait perdu sa page. La figure 4.1 expose les étapes réelles de la méthode `process`.

4.2 Décision native ou OCR par page

La solution la plus simple aurait été de lancer l'OCR sur toutes les pages. Elle aurait pourtant ignoré le texte déjà disponible dans les PDF numériques, ajouté un coût de calcul et pu introduire des erreurs de reconnaissance. La décision est donc prise par page. En mode `auto`, le processeur extrait les mots PDF et vérifie une condition de lisibilité : au moins douze caractères non blancs, une proportion d'au moins 95 % de caractères imprimables et des boîtes de surface positive. Si la condition échoue, la page est rendue et confiée à l'OCR. Cette règle explicite accélère les PDF numériques et conserve la capacité de traiter un document mixte. Elle n'est pas un classifieur appris de qualité : une couche cachée erronée mais suffisamment longue peut être préférée à l'image, et une page native légitimement très courte peut déclencher l'OCR.

FIGURE 4.1 – Pipeline de `DocumentProcessor` d’après le code et le contrat V1.

Les modes **native**, **ocr** et **hybrid** rendent la stratégie contrôlable. **native** ne reconnaît pas les images ; **ocr** ignore les mots natifs ; **hybrid** conserve deux ensembles de preuves identifiés et signale qu’ils ne sont pas fusionnés. Un résultat hybride ne doit donc pas être compté comme une source textuelle dédoublée. Le diagnostic par page permet de revenir sur une décision **auto** suspecte ; il ne corrige pas automatiquement une couche texte trompeuse.

4.3 Reconnaissance et prétraitement

Le chemin OCR rasterise la page, puis utilise `OCRRecognizer`. Les adaptateurs réemploient les fonctions de reconnaissance et de prétraitement de l’infrastructure historique, en sélectionnant une politique de page entière plutôt que des régions fixes de facture. Le dépôt prévoit PaddleOCR avec des modèles PP-OCRv4 mobiles et un repli Tesseract si celui-ci est configuré. Il n’envoie pas le contenu à une API d’inférence externe. Une vérification réelle de la qualité OCR requiert pourtant la présence locale du paquet et des poids ; elle n’a pas été exécutée dans l’environnement de rédaction. Les tests actuels garantissent les contrats et plusieurs cas déterministes, pas une précision de lecture des scans.

Le prétraitement peut redimensionner et redresser l’image. Le point délicat est géométrique : le moteur reconnaît sur l’image transformée, alors que l’interface doit surligner le document rendu. Le traitement expose donc la transformation affine et applique son inverse aux quatre coins de la boîte reconnue. Pour les mots natifs, il applique rotation PDF et échelle de rendu. L’algorithme publie ensuite une enveloppe rectangulaire dans le repère commun `rendered_page_pixels`, origine en haut à gauche. La boîte source et la matrice sont conservées ; une enveloppe après rotation n’est pas parfaitement inversible.




FIGURE 4.2 – Normalisation des boîtes natives et OCR vers le même espace d’affichage.

4.4 Modèle de preuve et géométrie

Une simple chaîne de texte aurait réduit le coût de sérialisation, mais elle aurait perdu la page, la zone et le chemin de reconnaissance. Un **EvidenceElement** conserve un identifiant, un texte brut, un numéro de page, une source, une boîte publique, la boîte source si disponible et la transformation. Une confiance est gardée lorsqu’elle vient du moteur ; elle reste nulle pour le texte natif. **PageDiagnostics** expose, entre autres, le chemin choisi, l’usage du repli, les avertissements et le temps observé. Le schéma évite ainsi d’inventer une confiance native ou une boîte manquante. Son coût est un contrat plus riche à maintenir et à tester à chaque adaptateur.

Entité	Information transmise	Ce qu’elle ne promet pas
DocumentResult	Identité du fichier, mode, pages, diagnostics	Exactitude métier ou stabilité éternelle des IDs
PageResult	Numéro physique, taille, éléments, géométrie	Ordre de lecture humain garanti
EvidenceElement	Texte, source, coordonnées, confiance éventuelle	Sens juridique ou montant validé
PageGeometry	Lignes, cellules candidates, colonnes alignées	Reconstruction sémantique d’un tableau

TABLE 4.1 – Responsabilités et limites du contrat de preuve.

La géométrie groupe les éléments par chevauchement vertical et alignements. Une « cellule candidate » peut n’être qu’un mot PDF ou une ligne OCR ; le code ne lui attribue pas encore une colonne métier. Cette prudence évite qu’un paragraphe aligné soit annoncé comme un tableau de prix. Les consommateurs peuvent utiliser les IDs pour reconstruire une ligne ou associer une valeur à son fragment exact.

4.5 Difficultés, vérification et limites

Les tests du producteur couvrent notamment la sélection de chemin, le contrat sérialisé, les rotations PDF, la provenance et l’absence de géométrie. La documentation relève une difficulté de lecture des PDF arabes où l’ordre natif diffère de l’ordre visuel. La fusion naïve des mots ferait perdre leur ordre source ; le contrat conserve **native_order** et la géométrie. Une autre difficulté est la coexistence d’une couche native faible avec une image lisible : l’heuristique reste observable dans les diagnostics et l’utilisateur peut forcer **ocr** ou **hybrid**.

Situation	Réponse actuelle	Risque restant
PDF tourné ou re-cadré	Matrice conservée et boîte publique dans le repère rendu	Enveloppe rectangulaire moins précise qu'un polygone
Page sans boîte exploitable	<code>bbox=null</code> , avertissement <code>missing_geometry</code>	Surlignage absent
Couche native trompeuse	Modes forcés <code>ocr</code> et <code>hybrid</code>	<code>auto</code> peut choisir le mauvais chemin
Deux sources en hybride	IDs distincts et avertissement	Doublons non fusionnés
Scan arabe de développement	Exécution OCR historique documentée	Résultat bruité, absence d'étiquettes validées

TABLE 4.2 – Réponses d'ingénierie et limites de la fondation documentaire.

Sur le PDF de référence de 30 pages et à texte natif, une exécution locale documentée donne environ 530 ms pour la seule étape DI ; elle ne mesure pas le cas OCR. Le chapitre 6 détaille ce protocole et évite d'en faire une garantie de service. La principale valeur de cette première tâche est donc moins un taux de reconnaissance revendiqué qu'une interface de preuve stable permettant plusieurs analyses métiers.

Chapitre 5

Tâche 2 : intelligence des cahiers des charges

5.1 Passage de la preuve au domaine métier

Un texte correctement extrait peut encore être inutilisable pour préparer une réponse. Le CDC demande une lecture de sa structure : titre, sections, articles, obligations, dates, garanties, annexes et bordereaux. Le **CDCAnalyzer** reçoit le **DocumentResult** par un adaptateur, construit un **TenderDocument**, puis transmet certaines pages candidates au module BOQ. Ce découplage rend possible l'analyse d'un PDF natif et d'une image OCR par le même chemin métier, à condition que les preuves textuelles soient suffisantes.

La hiérarchie n'est pas seulement une présentation. Une obligation sous une annexe technique n'a pas le même contexte qu'une clause administrative. Les modèles **Section**, **Article**, **Lot**, **Annex** et **Requirement** portent des références source. La composition détecte les titres, assemble les paragraphes, enrichit les exigences et identifie les documents spéciaux. Il s'agit de candidats structurés, pas d'une validation juridique.

5.2 Structure : titres, parties, articles et annexes

Les heuristiques de titres examinent le libellé et sa numérotation. Le travail de développement a montré deux échecs précis : les titres arabes *al-fasl* n'étaient pas identifiés comme articles, et des titres « Lot » numérotés étaient confondus avec des sections. La révision V2 ajoute des indices multilingues observés dans le corpus, reconnaît les « Partie I/II » comme niveaux supérieurs et garde les lots dans une collection distincte. Le résultat est meilleur sur les annotations de développement examinées au chapitre 6, sans preuve de généralisation à tous les formats arabes ou à tout OCR.

Les annexes sont repérées en préservant le numéro de page physique. La page reste centrale : elle permet à l'interface d'ouvrir le passage correspondant et à l'évaluateur de comparer les localisations. Pour les champs d'identité, une case vide du modèle documentaire reste manquante ; le logiciel ne crée ni date limite de soumission ni référence d'appel d'offres à partir du contexte voisin.




FIGURE 5.1 – Hiérarchie simplifiée du modèle CDC ; les lots restent distincts des sections.

5.3 Exigences, délais et données financières

Le module d'exigences classe des phrases candidates selon des motifs d'obligation et le contexte des articles ou annexes. Une simple recherche du verbe « doit » manquerait des variantes et confondrait parfois citation et obligation ; les indices structuraux apportent le contexte, sans résoudre tous les cas linguistiques. Les résultats ne sont pas exhaustifs : sur 26 exemples de faits positifs annotés, 14 sont retrouvés. Une évaluation limitée aux seuls exemples positifs ne donne ni précision ni rappel exhaustif du composant. Les faits financiers et temporels utilisent une normalisation de nombres, dates et durées. Le code maintient un lien entre la version accentuée de la source et la chaîne pliée utilisée pour la recherche ; cette correspondance d'offsets corrige un défaut où les extraits bruts perdaient leur place après normalisation.

L'interface de revue laisse un fait à l'état **unreviewed**, **approved** ou **corrected**, avec une correction explicite et un horodatage. Le résultat machine et sa preuve demeurent distincts de la décision humaine. Cette séparation est nécessaire pour pouvoir dire ce que l'outil a proposé et ce qu'un analyste a choisi ; elle rejoint les principes de conception d'interactions humain-IA où l'utilisateur doit pouvoir comprendre et corriger le système [12]. Le dépôt ne comporte pas d'identité de relecteur vérifiée ni de contrôle d'accès ; la revue ne constitue donc pas une piste d'audit complète de production.

5.4 Détection et extraction des bordereaux

Un BOQ rassemble des lignes de prestation avec, selon le formulaire, désignation, unité, quantité, prix unitaire, montant et totaux. Une seule règle universelle de colonnes serait séduisante, mais les gabarits changent leurs en-têtes, leurs positions et leurs lignes. Le flux en deux niveaux reconnaît d'abord une page candidate par les indices de titre et d'en-tête, puis tente de reconstruire les lignes. Le parseur spécialisé **MALE_MUNICIPAL_MAINTENANCE_BOQ_V1** exploite la géométrie connue du formulaire ministériel. Le parseur **GENERIC_LAYOUT_BOQ_V1** cherche des en-têtes sémantiques placés et attribue les fragments de ligne aux colonnes observées. La spécialisation est prioritaire lorsqu'elle correspond ; elle évite de dégrader un format connu par une heuristique plus large, au prix d'une couverture réduite sur d'autres formats.

La reconstruction générique gère dans les tests un en-tête sur deux lignes, une désignation repliée avec conservation des deux preuves, des en-têtes répétés et un libellé de colonne explicitement TTC. La reconnaissance du niveau HT ou TTC vient des mots présents dans l'en-tête, pas d'une hypothèse comptable. Les descriptions très irrégulières, les cellules fusionnées et la continuation




FIGURE 5.2 – Extraction BOQ spécialisée ou générique, suivie de contrôles explicites.

multipage sans nouvel en-tête restent hors du domaine validé. Une ligne peut être détectée mais garder des valeurs numériques nulles. Le système ne remplit pas les cases manquantes par déduction.

Aspect	Extracteur spécialisé	Extracteur générique
Déclenchement	Famille ministérielle connue	Indices de BOQ + en-tête positionné
Colonnes	Géométrie du formulaire	Concepts d'en-tête et positions observées
Atout	Stabilité sur la référence connue	Essai de transfert à d'autres gabarits
Preuve actuelle	Gabarit réel vide et fixtures synthétiques	Régressions synthétiques positionnées
Risque principal	Couverture étroite	Variabilité du tableau et de l'OCR

TABLE 5.1 – Portée effective des deux extracteurs BOQ.

5.5 Le cas décisif du formulaire vide

Le PDF réel de référence compte 30 pages et son Annexe 05 se trouve à la page physique 25. Le bordereau y présente cinq emplacements d'articles, numérotés 01 à 05. Les désignations, quantités, prix et montants ne sont pas renseignés. Les contrôles arithmétiques retournent `NOT_CHECKABLE` plutôt que `VALID` pour les sommes. Cette distinction est fondamentale : le cas vérifie la localisation d'un gabarit et la conservation du vide, mais ne peut servir à calculer la précision des nombres sur des offres achevées. La figure 5.3 reproduit un extrait du document de référence pour rendre l'absence observable.

Lot N°

Article	Désignation	Qté	Prix HTVA (DT)		Prix TTC (DT)	
			Unité	Total	Unité	Total
01	L'unité :DT					
02	L'unité :DT					
03	L'unité :DT					
04	L'unité :DT					
05	L'unité :DT					
Total HTVA						DT
TVA (.....%)						DT
Total TTC						DT

Arrêtée le présent bordereau des prix - devis estimatif à la somme de :

..... DT toutes taxes comprises.

FIGURE 5.3 – Extrait authentique de l'Annexe 05 du PDF de référence, page 25 : emplacements de bordereau non remplis.

La validation compare les montants seulement lorsque quantité et prix existent. Elle emploie des nombres décimaux et une tolérance définie dans le module de contrôle ; une absence devient NOT_CHECKABLE, une incohérence mesurable peut être signalée. Des fixtures synthétiques testent par exemple un nombre français, une quantité manquante et une erreur de multiplication. Ces cas prouvent le comportement du programme sur des entrées contrôlées, pas sa robustesse sur des offres réelles variées.

5.6 Ask Tender : retrouver avant de formuler

Ask Tender indexe les passages et les faits déjà structurés de `TenderDocument` pour répondre à une question. Une génération directe sur le PDF entier rendrait plus difficile l'attribution de la réponse à une page précise. Le système commence donc par retrouver des preuves : la requête est normalisée, les mots fréquents sont réduits et une carte limitée de concepts d'achat public augmente le score de passages déjà observés (délai, garantie, durée, pièces, paiement ou bordereau). Les alias améliorent le classement ; ils ne créent jamais une valeur factuelle. Les résultats sont dédoublés par élément source et exposent page et preuve. Un chemin déterministe formule certaines réponses courtes ; Ollama peut générer localement depuis les passages sélectionnés, si un modèle est disponible. Ce choix facilite l'audit et l'exécution locale, mais sa récupération lexicale peut manquer une paraphrase nouvelle. En l'absence de modèle local, l'interface signale le repli.

Une citation est une aide à la vérification, pas une garantie automatique de pertinence. Les tests de récupération disponibles portent sur quatre puis sept questions synthétiques revues. La

page attendue apparaît dans les trois premiers résultats pour les quatre premières ; pour les sept nouvelles, elle se trouve en première position dans les sept cas. Les textes et la formulation de ces questions étant contrôlés, on ne peut pas extrapoler un taux de bonne réponse en situation réelle.

The screenshot displays the 'Ask Tender' interface. At the top, there are tabs: 'Vue d'ensemble', 'Exigences', 'Finances & Délais', and 'Plus'. Below these, there are sub-tabs: 'Bordereau', 'Sources', and 'Ask Tender' (which is highlighted with a red box). The main section is titled 'QUESTIONS AU DOSSIER' and 'Ask Tender'. Below this, it says 'Les réponses doivent être accompagnées de preuves du document.' There is a text input field for 'Votre question' with the text 'Quel est le total TTC indiqué dans le bordereau ?'. Below the input field is a button labeled 'Poser la question'. Below this, there is a section titled 'Génération locale indisponible' with the text 'Des passages correspondants sont présentés ci-dessous pour vérification.' Below this, there is a section titled 'Passages retrouvés' with a list of two items: 'BORDERAU DES PRIX - DEVIS ESTIMATIF · p. 1' with 'Total TTC 416,500' and 'BORDERAU DES PRIX - DEVIS ESTIMATIF · p. 1' with 'Prix HTVA Prix TTC'.

FIGURE 5.4 – Vue réelle d’Ask Tender sur une fixture BOQ synthétique : passages cités et indisponibilité explicite de la génération locale.

5.7 Persistance, interface et chiffrage




FIGURE 5.5 – Workspace exécuté localement avec la fixture BOQ synthétique : structure à gauche, document source au centre et analyse à droite.

L'API FastAPI publie les routes d'analyse, de chargement de page, de sauvegarde, de recherche, d'interrogation, de revue et d'export CSV. Le stockage local associe un identifiant opaque à la réponse enregistrée. Le parcours de bibliothèque recherche par nom ou identifiant et rouvre une analyse sans réexécuter le producteur de preuves. Les tests API remplacent même `DocumentProcessor` par un composant qui échouerait s'il était appelé lors de certaines réouvertures. L'interface offre un visualiseur de la source, un espace CDC, un espace BOQ et un brouillon de prix.

Le brouillon de chiffrage ne modifie pas le BOQ extrait. Écraser la valeur source par une saisie corrigerait l'affichage mais détruirait la possibilité de contrôler l'erreur initiale. Pour chaque ligne, le système distingue donc les quantités ou prix lus dans la source, les saisies de l'utilisateur et les montants calculés. Une empreinte du BOQ détecte le cas où le brouillon ne correspond plus à l'analyse de départ. Le calcul emploie `Decimal` ; un taux de TVA n'est appliqué que s'il est explicitement connu dans la source ou fourni dans un scénario contrôlé. Le PDF réel de référence ne donne ni quantités, ni prix, ni taux de TVA. Le programme ne doit donc pas présenter un total TTC réel pour ce document.

Vue d'ensemble
Exigences
Finances & Délais
Plus ▾

Bordereau
Sources
Ask Tender

BORDEREAU · BROUILLON SÉPARÉ

Chiffrage du bordereau

Les valeurs du document restent inchangées. Les prix saisis et montants calculés sont enregistrés séparément.

Consulter le bordereau
Exporter le chiffrage

Document : données source
Saisie : prix du soumissionnaire

Calcul : montant obtenu

1 / 5 lignes chiffrées
À vérifier
Enregistré

N° Document	Désignation Document	Unité Document	Quantité Document	Prix U. HT Saisie
01	Entretien voirie	—	2p.1	130.000
02	Refection reseau	—	1p.1	—
03	—	—	—p.1	—
04	—	—	—p.1	—

FIGURE 5.6 – Brouillon de chiffrage sur la même fixture synthétique : origine des valeurs et état « à vérifier » après une saisie divergente.

Le CSV extrait et le CSV de chiffrage sont deux exports séparés. Les champs textuels susceptibles d'être interprétés comme formule par un tableur sont neutralisés. La sauvegarde du brouillon est indépendante de la réponse d'analyse et la revue humaine conserve également sa propre trace. Ce sont des mécanismes de fiabilité d'une démonstration locale ; ils ne remplacent ni une politique de droits ni une procédure de validation des offres.

Chapitre 6

Validation, résultats et analyse des erreurs

6.1 Protocole : trois niveaux de preuve

L'évaluation n'agrège pas toutes les vérifications en un score global. Un test unitaire contrôle une règle sur une entrée connue ; un benchmark annoté compare une sortie à une référence limitée ; un parcours de bout en bout vérifie l'enchaînement de l'interface et de la persistance. Aucun de ces niveaux, pris isolément, ne démontre l'exactitude d'un système sur la population entière des appels d'offres. Les jeux sont donc décrits avec leur origine et leur statut d'annotation.

Non établi	Validation indépendante à l'échelle d'exploitation
À construire	Corpus réel rempli et tenu à l'écart
Partiel	Annotations CDC de développement ; BOQ réel vide
Disponible	Fixtures synthétiques et parcours local
Disponible	Tests unitaires et intégration sur entrées connues

FIGURE 6.1 – Maturité des preuves d'évaluation : la largeur décroissante signale le travail restant, sans convertir les niveaux en score de précision.

Le corpus de développement CDC V2 comprend sept documents traités du PDF à l'analyse ; six disposent d'étiquettes de source vérifiées pour les catégories scorées. Un scan arabe de 37 pages a été exécuté historiquement avec OCR, mais ses annotations restent provisoires et il est exclu des scores. Pour le BOQ, une référence réelle vide sert à mesurer seulement la structure. Les formulaires synthétiques contrôlent les cas numériques et géométriques. Enfin, la récupération Ask Tender est éprouvée sur de petites questions synthétiques revues. La tableau 6.1 explicite ce découpage.

6.2 Tests du logiciel et contrat documentaire

La commande `pytest -q -rs`, réexécutée le 5 octobre 2026 sur le code applicatif inchangé depuis f292de8, donne **305 tests réussis, aucun échec, un test ignoré et un avertissement**

Ensemble	Volume	Ce qui est observable	Ce qui ne l'est pas
CDC développement	7 traités ; 6 vérifiés	Sections, annexes et exemples positifs annotés	Généralisation à un corpus indépendant
BOQ réel vide	1 PDF, 30 pages	Page 25, 5 lignes structurales, champs vides	Précision des prix d'offres remplies
BOQ réel rempli	0	Aucun score possible	Extraction numérique réelle
BOQ synthétique	Fixtures contrôlées	Règles de parsing, manque et calcul	Exactitude en production
Ask Tender synthétique	4 puis 7 questions	Rang de la page attendue	Qualité générale des réponses

TABLE 6.1 – Séparation des cohortes et limites de mesure.

en 33,05 s. Le test ignoré est la vérification réelle Paddle nécessitant `RUN_REAL_OCR=1` et des modèles locaux. L'avertissement concerne la dépréciation de la combinaison Starlette/httpx utilisée par TestClient. Les tests couvrent notamment le contrat DI, la rotation des pages, les adaptateurs, l'analyse CDC, les cas BOQ, les routes V2 et la persistance. Ils ne sont pas un taux de réussite documentaire : beaucoup reposent sur des fixtures conçues pour reproduire un comportement attendu.

La conformité OCR du parcours natif est particulièrement importante pour l'étude : la référence réelle possède du texte sélectionnable sur ses 30 pages. Le diagnostic de la mesure locale indique zéro page OCR et zéro repli. Le nombre d'éléments de preuve rapporté par cette exécution est 10 451 ; il s'agit d'éléments textuels du PDF, pas de champs métier correctement extraits. Les tests de schéma protègent la sérialisation `DocumentResult` et l'identité des références de preuve à travers les consommateurs.

6.3 Mesures CDC et interprétation

Sur les catégories entièrement revues, la version V2 retrouve les neuf sections annotées sans faux positif ni omission dans ce sous-ensemble : précision et rappel 9/9. Les 27 annexes annotées sont également retrouvées. Ces ratios portent sur des listes complètes pour les documents sélectionnés, pas sur tout document futur. Les titres d'articles et les faits d'exigence, eux, sont des *exemples positifs* sélectionnés : 19 titres sur 19 sont retrouvés, mais aucune précision de tous les articles ne peut être calculée. Parmi 26 faits positifs, 14 sont détectés ; sur ces 14, sept valeurs normalisées correspondent à l'attendu et les 14 pages de preuve sont correctes. Les douze faits manqués et sept valeurs incorrectes restent des échecs visibles.

Le changement V2 cible des erreurs identifiées : titres arabes non reconnus, frontières « Partie » et « Lot » mal classées. La comparaison V1/V2 sur les mêmes labels montre que les sections passent de 5 vrais positifs, 2 faux positifs et 4 omissions à 9, 0 et 0. Elle ne démontre pas une progression sur un jeu tenu à l'écart, puisque le même corpus a guidé l'évolution. Les 14 faits d'exigence détectés restent inchangés en nombre ; une meilleure structure rend deux normalisations visibles à l'évaluateur, sans changement général du parseur de valeur.

6.4 Bordereau et contrôle de l'absence

Le mécanisme d'évaluation BOQ V2 distingue `real_completed`, `real_empty_template` et `synthetic`. Dans la cohorte réelle vide, la présence du tableau, sa page candidate et son nombre

Objet scoré	Résultat V2	Portée correcte
Sections majeures	9 vrais positifs, 0 FP, 0 FN	Listes complètes revues sur le sous-ensemble
Annexes	27/27, 0 FP, 0 FN	Listes complètes revues sur le sous-ensemble
Titres d'articles	19/19 exemples positifs	Aucun calcul de précision exhaustive
Exigences	14/26 exemples positifs retrouvés	12 exemples non détectés
Valeurs normalisées	7/14 parmi les détectés	Sept valeurs détectées mais non conformes
Pages des faits détectés	14/14	Provenance des seuls faits retrouvés
BOQ présents dans CDC pilote	3/3 pages chevauchées	Détection sur sous-ensemble de développement

TABLE 6.2 – Résultats du benchmark CDC V2 sur annotations de développement ; aucune métrique globale n'est déduite.

de lignes sont corrects chacun sur l'unique document. Les cinq numéros d'article sont retrouvés et 25 cellules explicitement vides de quantité ou de montant demeurent vides. Ces comptes portent sur *un seul gabarit vide*. Aucune précision, rappel ou erreur absolue des montants sur un bordereau réel rempli ne peut être annoncé. Les tests synthétiques vérifient notamment les formes numériques françaises, les lignes à valeur absente, l'erreur arithmétique, un décalage géométrique et les calculs du brouillon.

Un exemple de chiffrage de démonstration calcule 1000 multiplié par 12,500 pour obtenir 12 500,000 HT ; un taux de 19 % saisi *dans ce scénario synthétique* donne 2 375,000 de taxe et 14 875,00000 TTC. Ces valeurs ne viennent pas du PDF de référence. Elles vérifient l'arithmétique, la persistance après redémarrage et l'affichage, sans établir un devis réel.

6.5 Ask Tender et parcours utilisateur

Quatre questions synthétiques initiales placent la page attendue parmi les trois premières réponses dans 4/4 cas. La mise à jour suivante couvre sept autres questions synthétiques ; leur page attendue arrive en tête dans 7/7 cas, et donc également dans les trois et sept premières places. Le protocole évalue la *présence de la bonne page dans le classement*, pas la véracité complète d'une réponse rédigée. Sur le document de référence, une formulation du délai de dépôt a remonté des pages liées au sujet, mais des questions larges peuvent aussi favoriser un passage voisin.

Un parcours navigateur local documenté a couvert le chargement d'un bordereau synthétique, l'ouverture du workspace, le chiffrage et ses calculs, le rafraîchissement, la réouverture après redémarrage, une citation Ask Tender et la bibliothèque. L'export CSV a été vérifié côté API ; le téléchargement navigateur n'a pas produit de chemin de fichier observable dans l'automatisation. La suppression a été testée par API sur un enregistrement jetable. Cette description distingue précisément ce qui a été vu dans le navigateur de ce que prouvent seulement les tests de route.

6.6 Temps observés et erreurs résiduelles

Une mesure séquentielle locale, sur le PDF natif de 30 pages et le code final du dépôt, rapporte 530,0 ms pour DI, 270,6 ms pour CDC, 248,5 ms pour le balayage BOQ de toutes les pages,

611,6 ms pour la composition V2 et 1 037,6 ms pour la récupération de six passages Ask Tender. Un calcul de prix sur cinq lignes prend 1,478 ms dans cette exécution. L'écriture d'une réponse JSON de 3,53 Mo prend 54,2 ms et sa lecture/analyse 34,1 ms. Les étapes sont mesurées séparément et ne doivent pas être additionnées aveuglément : le balayage BOQ final diffère d'une mesure historique limitée à la page spécialisée. Aucun intervalle de confiance, test de charge ou mesure du chemin OCR scanné n'accompagne ces nombres.

Étape locale	Temps observé	Contexte
Document Intelligence	530,0 ms	PDF natif 30 pages, environnement chaud
CDC Analyzer	270,6 ms	Même référence
Balayage BOQ	248,5 ms	Vérification des 30 pages
Composition réponse V2	611,6 ms	Assemblage du contrat API
Ask Tender	1 037,6 ms	Récupération de six passages
Calcul prix cinq lignes	1,478 ms	Brouillon local

TABLE 6.3 – Observations d'une seule exécution locale, sans garantie de latence.

L'analyse des échecs reste prioritaire. Les douze faits CDC non détectés comprennent des clauses arabes et des formulations non couvertes. Sept valeurs détectées ont une normalisation incorrecte ou absente, notamment une date, une garantie et des pénalités. Le scan arabe de développement a produit historiquement 1 192 éléments OCR sur 37 pages, mais un texte bruité et aucune annotation définitive : l'échec ne peut être attribué séparément au reconnaiseur ou à l'analyseur. Le parseur générique BOQ présuppose encore des colonnes stables et ne prouve pas la lecture de tables arbitraires.

Échec observé	Cause plausible appuyée par les traces	Réponse et risque restant
Titres arabes absents	Cues de titre V1 insuffisants, ordre de mots variable	Règles V2 ; scans arabes encore non validés
Faits non détectés	Motifs d'obligation incomplets	12/26 exemples manqués ; élargir après annotation
Valeurs financières fausses	Normalisation sémantique limitée	Conserver source et revue ; 7/14 valeurs correctes
BOQ générique irrégulier	Colonnes et hauteurs variables	Tests synthétiques ciblés ; corpus réel rempli requis
Question générale mal classée	Récupération lexicale sans compréhension vectorielle	Citations visibles ; évaluation diversifiée requise

TABLE 6.4 – Erreurs conservées dans l'analyse plutôt que masquées par un score global.

Chapitre 7

Exécution locale, limites et perspectives

7.1 Architecture exécutable

L'application expose une API FastAPI et des pages web statiques. La commande de développement documentée est `python -m uvicorn app.main:app -host 127.0.0.1 -port 8000`. Les analyses V2 produisent un identifiant de stockage et une réponse réutilisable ; le visualiseur peut servir la page PDF pour inspection. La persistance locale permet de retrouver une analyse et son brouillon de prix après redémarrage du processus. FastAPI fournit ici le cadre des routes et de la validation des requêtes [13].

Le dépôt contient des fichiers de dépendances et un verrou Windows/Python 3.11, mais aucun `Dockerfile` versionné n'a été trouvé dans l'état inspecté. La documentation indique que l'installation Linux/Docker n'est pas vérifiée. La conteneurisation reste une perspective de reproductibilité [14], qui demanderait aussi le provisionnement des poids OCR, des sauvegardes et des protections applicatives. La génération Ollama demeure locale et optionnelle ; des passages cités restent disponibles lorsqu'elle est absente.

7.2 Limites opérationnelles et scientifiques

Le premier obstacle scientifique est le manque d'un corpus de bordereaux réels remplis, indépendamment étiquetés. Le document réel inclus ne permet que de contrôler le tableau vide. Le second est la validation des scans : le test de Paddle réel est optionnel et ignoré dans l'environnement de rédaction, et le scan arabe exploratoire n'a pas d'annotations définitives. Les résultats CDC sont obtenus sur un corpus de développement qui a guidé les corrections, sans jeu final tenu à l'écart. Enfin, l'évaluation Ask Tender est courte et synthétique ; une citation correctement attachée ne prouve pas une réponse juste.

Sur le plan logiciel, les tables multipages sans nouvel en-tête, les cellules fusionnées et l'OCR fragmenté restent des cas faibles du BOQ générique. Le chiffage ne peut appliquer une TVA ou un arrondi légalement pertinents sans règle explicite du dossier. L'export du brouillon en CSV existe, mais le remplissage du PDF original n'est pas implémenté. La revue d'un fait conserve la correction et l'horodatage, sans identité authentifiée du relecteur ni historique complet des versions. Le stockage local ne constitue pas une solution multi-utilisateur sécurisée.

Limite	Conséquence	Travail prioritaire
Aucun BOQ réel rem- pli annoté	Précision des valeurs inconnue	Constituer un corpus diversifié et scorer par champ
OCR réel non rejoué ici	Qualité scannée non établie	Provisionner les modèles, annoter scans mixtes
Corpus CDC de déve- loppement	Risque d'ajustement aux exemples	Évaluer sur dossiers tenus à l'écart
Récupération lexicale	Paraphrases hors carte moins fiables	Jugement humain de pertinence et couverture
Absence d'authentifi- cation	Usage externe non sûr	Droits, journalisation, sauvegardes et rétention
PDF final non rempli	Soumission encore manuelle	Export contrôlé après règles métier validées

TABLE 7.1 – Limites à lever avant une exploitation au-delà d'une démonstration supervisée.

7.3 Feuille de route fondée sur les erreurs

La première étape devrait être la collecte consentie de bordereaux remplis provenant de plusieurs émetteurs, avec étiquettes indépendantes pour la page, la ligne et chaque valeur. Les résultats seraient publiés séparément pour documents natifs, scans, gabarits connus et gabarits nouveaux. La deuxième étape serait un protocole OCR réel sur des PDF mixtes, avec version des modèles et mesure de la dégradation jusqu'aux champs métier ; un taux de reconnaissance isolé ne suffit pas si la page ou le montant reste mal attribué. La troisième étape concerne l'analyse : traiter les douze faits CDC manqués et les sept normalisations incorrectes à partir de classes d'erreur, puis confirmer les changements sur un jeu distinct.

La quatrième étape renforcerait le workflow : revue humaine authentifiée, journal d'édition, seuils de confiance calibrés par famille documentaire et visibilité des champs non vérifiables. Pour une mise en service, il faudrait également sauvegarde et restauration, contrôle d'accès par dossier, règles de conservation, tests de charge et supervision des erreurs. L'export dans un formulaire BOQ officiel ne devrait venir qu'après validation des règles de taxe, d'arrondi et de la correspondance des colonnes par les responsables métier. Cette séquence privilégie la qualité des décisions et la traçabilité sur l'ajout prématuré de fonctionnalités.

Conclusion générale

Ce travail a relié deux problèmes souvent traités séparément : lire les caractères d'un document et comprendre assez de sa structure pour aider un analyste à préparer un dossier. La première tâche a fourni un contrat de preuves multi-pages où chaque élément garde sa source, sa page et ses coordonnées. La seconde a exploité ce contrat pour produire une hiérarchie de cahier des charges, des faits candidats, des bordereaux et des passages interrogables. L'espace de travail, le stockage local, la revue et le chiffage séparé transforment ces résultats en parcours consultable.

La validation établit une base logicielle cohérente : 305 tests réussis lors de la vérification actuelle, des mesures de développement CDC explicitement bornées et un parcours local documenté. Elle établit aussi ce qui manque. Le seul BOQ réel de référence est vide ; les calculs vérifiés sur des fixtures synthétiques ne prouvent pas l'extraction de prix réels. Le test OCR avec modèles locaux n'a pas été rejoué pendant la rédaction, et la récupération de questions reste évaluée sur un petit ensemble contrôlé. Ces limites ne diminuent pas la valeur de la plateforme comme prototype d'ingénierie : elles définissent précisément le travail de données, de mesure et de contrôle nécessaire avant une utilisation engageante.

La contribution principale est la continuité de la preuve, du pixel ou du mot PDF jusqu'à la valeur présentée à l'utilisateur. Pour Aymen, le projet consolide des compétences concrètes d'ingénierie Data Science/IA : concevoir des contrats de données, intégrer OCR et extraction d'information, interpréter des annotations limitées, analyser les échecs et faire vérifier les sorties par un humain. Cette expérience rappelle qu'un système d'IA utile se juge aussi sur sa traçabilité et sa capacité à signaler ce qu'il ignore. Pour la suite, le progrès le plus décisif sera un corpus indépendant de CDC et de BOQ remplis, accompagné de protocoles de revue et de sécurité adaptés au contexte métier.

Références

- [1] UDGROUPE. *UDGroup – Universal Digital Group*. URL : <https://udgroup.com.tn/> (visité le 05/10/2026).
- [2] IBM. *CRISP-DM View*. URL : <https://www.ibm.com/docs/en/spss-modeler/saas?topic=projects-crisp-dm-view> (visité le 05/10/2026).
- [3] PYMUPDF. *Text extraction recipes*. URL : <https://pymupdf.readthedocs.io/en/latest/recipes-text.html> (visité le 05/10/2026).
- [4] PADDLEOCR. *PaddleOCR documentation : Quick Start*. URL : https://www.paddleocr.ai/latest/en/quick_start.html (visité le 05/10/2026).
- [5] TESSERACT OCR. *Tesseract OCR README*. URL : <https://github.com/tesseract-ocr/tesseract/blob/main/README.md> (visité le 05/10/2026).
- [6] Yiheng XU et al. « LayoutLM : Pre-training of Text and Layout for Document Image Understanding ». In : *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2020. DOI : [10.1145/3394486.3403172](https://doi.org/10.1145/3394486.3403172). URL : <https://arxiv.org/abs/1912.13318>.
- [7] Yang XU et al. « LayoutLMv2 : Multi-modal Pre-training for Visually-rich Document Understanding ». In : *Proceedings of ACL-IJCNLP*. 2021. URL : <https://aclanthology.org/2021.acl-long.201/>.
- [8] Yiheng XU et al. « LayoutXLM : Multimodal Pre-training for Multilingual Visually-rich Document Understanding ». In : *arXiv preprint arXiv :2104.08836* (2021). URL : <https://arxiv.org/abs/2104.08836>.
- [9] Geewook KIM et al. « OCR-Free Document Understanding Transformer ». In : *European Conference on Computer Vision*. 2022. URL : https://www.ecva.net/papers/eccv_2022/papers_ECCV/html/8042_ECCV_2022_paper.php.
- [10] Patrick LEWIS et al. « Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks ». In : *arXiv preprint arXiv :2005.11401* (2020). URL : <https://arxiv.org/abs/2005.11401>.
- [11] Christopher D. MANNING, Prabhakar RAGHAVAN et Hinrich SCHÜTZE. *Introduction to Information Retrieval*. Cambridge University Press, 2008. URL : <https://nlp.stanford.edu/IR-book/information-retrieval-book.html>.
- [12] Saleema AMERSHI et al. « Guidelines for Human-AI Interaction ». In : *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*. 2019. DOI : [10.1145/3290605.3300233](https://doi.org/10.1145/3290605.3300233). URL : <https://www.microsoft.com/en-us/research/publication/guidelines-for-human-ai-interaction/>.
- [13] FASTAPI. *Tutorial – User Guide*. URL : <https://fastapi.tiangolo.com/tutorial/> (visité le 05/10/2026).
- [14] DOCKER. *What is a container ?* URL : <https://docs.docker.com/get-started/docker-concepts/the-basics/what-is-a-container/> (visité le 05/10/2026).

Annexe A

Traçabilité de l'évaluation

A.1 Commandes et artefacts

La suite courante se lance à la racine du dépôt avec `pytest -q -rs`. L'état exact utilisé pour ce rapport est le commit `f292de8`. Les métriques CDC de développement sont archivées dans `benchmarks/cdc_real_v1/metrics_v2.json`; les explications sont dans `docs/CDC_ANALYZER_V2_EVALUATION.md`. La vérité terrain du gabarit vide est `datasets/boq/male_municipal_maintenance_v1/ground_truth/reference_empty.json`. Les cas contrôlés correspondants sont sous `synthetic/`. Les observations chronométrées sont dans `docs/PERFORMANCE_REPORT.md`. Un état ultérieur du dépôt nécessite une nouvelle exécution avant de réutiliser les nombres du présent rapport.

A.2 Exemples de routes de consultation

Route	Usage
POST <code>/api/v2/cdc/analyze</code>	Charge et analyse un document
GET <code>/api/v2/cdc</code>	Liste les analyses stockées
GET <code>/api/v2/cdc/{id}</code>	Rouvre une analyse par identifiant
POST <code>/api/v2/cdc/{id}/ask</code>	Interroge les preuves enregistrées
GET <code>/api/v2/cdc/{id}/boq.csv</code>	Exporte le BOQ extrait
GET <code>.../boq/{n}/pricing</code>	Ouvre un brouillon de chiffrage

TABLE A.1 – Sélection de routes V2 du parcours CDC ; les points de suspension abrègent le préfixe `/api/v2/cdc/{id}`.

A.3 Lecture prudente des nombres

Les 9/9 sections et 27/27 annexes concernent les listes entièrement annotées du sous-ensemble de développement. Les 19/19 articles représentent seulement des exemples positifs. Les 14/26 exigences et 7/14 valeurs normalisées révèlent des erreurs non résolues. Les 5 lignes du document BOQ réel sont des emplacements vides ; aucune multiplication entre prix et quantité n'y est mesurable. Les temps sont des observations locales isolées. Cette grille de lecture doit accompagner toute présentation orale des résultats.